

Cours Codage de l'information

Mendy Fatnassi

10 décembre 2020

Table des matières

1	Codage Physique / Codage sans perte	3
1.1	Introduction	3
1.2	Transmissions Avec/Sans perte	3
1.3	Mode de transmission/Codage	3
1.3.1	NRZ (No Return to Zero)	3
1.3.2	Unipolaire	4
1.3.3	Bipolaire	5
1.3.4	Manchester	5
1.3.5	Delay Mode (Miller)	5
1.3.6	HBDN	6
1.4	Entropie	6
1.5	Codage Source	7
1.5.1	Code de Shannon-Fano	7
1.5.2	Code de Huffman	8
1.5.3	Code Arithmetique	8
2	Code Correcteur d'erreur / Code d'etalelement	9
2.1	Introduction	9
2.2	Code Correcteur	9
2.2.1	Code en Bloc	9
2.2.2	Code Convolutionnel	9
2.3	Detection et Correction d'erreur	10
2.4	Generation et Detection	11
2.5	Sequence d'hadamard	12
3	Code Cyclique/ Pseudo-Aleatoire	14
3.1	Code Pseudo Aleatoire	14
3.1.1	Code a Longueur Maximal LM	14
3.1.2	Code Gold	15
3.1.3	Code JPL	17
3.2	Code Cyclique	17
4	Temps Reel	19

Chapitre 1 : Codage Physique / Codage sans perte

1.1 Introduction

C'est en 1948 grace aux travaux de shannon , que la theorie de l'information a pris sa forme actuelle.

Le traitementdu contenue d'une source d'information peux etre envisage sous deux forme :

- Sans perte d'information.
- Avec perte d'information.

1.2 Transmissions Avec/Sans perte

Avec perte :

Exemple : Signal analogique stereo , bande de frequence 0 a 20 Khz , echantillonnage 44,1Khz , quantification de 16b.

Donc $44.1 \times 10 + 3 \times 16 \times 2 = 1.411$ MBits/sec

Ex MP3 : reduction a 128 Kbits/sec avec un taux de compression de 11.

Taux de compression :

- Elimination des composantes spectrales.
- Utilisation du codage de Huffman.

La transmission numerique passe par un support physique qui interprete la communication sous forme de signaux numerique. Ainsi des donnees analogique devront prealablement erte numerise. Le codage du signaux peux se faire sur 2 (-X,X) ou 3 niveaux (-X,0,X).

1.3 Mode de transmission/Codage

Voici quelque mode de transmission :


1.3.1 NRZ (No Return to Zero)

Avantage : Le recepteur peux determiner la presence ou non d'un signal.

Inconvenient : Difficulté de synchronisation.

$0 \Rightarrow -X$

$1 \Rightarrow +X$



Quelque dérivée du NRZ : RZ(Return to Zero) & NRZI (Inverted).

RZ

:
pareil que pour NRZ sauf que entre deux bits 1 consécutif il y a un changement d'état au lieu de rester sur $+X$ on fera $+X-X+X-X$.

NRZI

:
 $1 \Rightarrow$ le signal change d'état , $0 \Rightarrow$ aucun changement d'état.

1.3.2 Unipolaire

Avantage : Réduction encore plus significative du spectre.


Inconvénient : Impossibilité de distinguer une suite de 0 et l'absence d'information.

$0 \Rightarrow 0$ (tension nulle)

$1 \Rightarrow +X$


1.3.3 Bipolaire

:
 0 \Rightarrow lorsque le bit est a 0
 1 \Rightarrow alternativement $+X$ et $-X$



1.3.4 Manchester

Une transition est introduite au milieu de l'intervalle significatif.
 0 \Rightarrow Transition du niveau bas vers le niveau haut ,front montant.
 1 \Rightarrow Transition di niveau haut vers le niveau bas , front descendant.




1.3.5 Delay Mode (Miller)

Signal intermediaire identique au coodage manchester , puis suppression d'une transition sur deux.

Transition (front montant|descendant) \Rightarrow 1

Pas de transition au milieu du bit 0

Transition en de fin de bit 0 si suivi d'un autre 0



1.3.6 HBDN

:

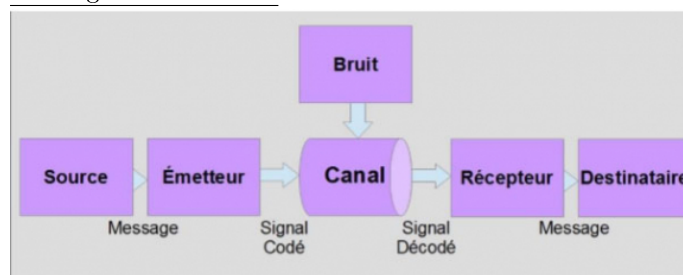
1.4 Entropie

La théorie de l'information menée par Shannon, qui est une théorie probabiliste permettant de quantifier le contenu moyen en information d'un ensemble de messages, dont le codage informatique satisfait une distribution statistique précise. Ce domaine trouve son origine scientifique avec Claude Shannon qui en est le père fondateur avec son article "A Mathematical Theory of Communication" publié en 1949.

Parmi les branches importantes de la théorie de l'information de Shannon, on peut citer :

- Le codage de l'information
- La mesure quantitative de redondance d'un texte
- La compression de données
- La cryptographie

Paradigme de Shannon :



L'entropie permet de mesurer la quantité d'information moyenne d'un ensemble d'événements (en particulier de messages) et de mesurer son incertitude. Supposons maintenant que les boîtes soient de diverses couleurs : n_1 boîtes de

couleur C_1 , n_2 boîtes de couleur C_2 ... , n_k boîtes de couleurs C_k , avec $n_1 + n_2 + \dots + n_k = N$. La personne C sait de quelle couleur est la boîte recherchée. Quel est le prix de cette information? .

On la note $H(I) : \sum_{i \in I} p_i \log_2 p_i = -(p_i \log p_i + \dots + p_{i+n} \log p_{i+n})$

avec $p_i = \frac{n_i}{N}$ la probabilité associée à l'apparition de l'évènement i .

Donc l'information « la boîte est de couleur C_1 » vaut $\log N/n_1$, et cette éventualité a une probabilité n_1/N .

Entropie d'une source discret (numerique :0,1) , si on a un message aleatoire avec un tirage de 27 lettres (alphabet + espace) , on aurait comme entropie $H = \log 27 = 4,75$ bits.

Entropie relative , elle dependra du contexte de son message (limité par le corpus de la langue) et auras un pourcentage de liberté

1.5 Codage Source

Il existe des code a longueur fixe ou tous les mots ont la meme longueur et possede le meme nombre de symbole et les code a longueur variables ou la longueur varie en fonction de leur frequence d'apparition .Un mot sera d'autant plus long que sa probabillite d'apparition est petite.

1.5.1 Code de Shannon-Fano

Deroulement de l'algo :

1-Trier les probabilité par ordre decroissant

2-On separe l'ensemble en 2 groupes (de somme a peu pres egale)

3- $\sum 1 = \sum 2 \Rightarrow \sum 1 - > 0, \sum 2 - > 1$

4-On divise en 2 les deux sous-groupe $\sum 1/2 = \sum 11 - > 0, \sum 21 - > 1$ et $\sum 2/2 = \sum 21 - > 0, \sum 22 - > 1$

5-Bouclez de l'etape 4 a 5 jusqu'a tant de que le tableau soit remplie

Exemple :

a_i	$p(a_i)$	1	2	3	4	Code
a_1	0.36	0	00			00
a_2	0.18		01			01
a_3	0.18	1	10			10
a_4	0.12		11	110		110
a_5	0.09			111	1110	1110
a_6	0.07				1111	1111

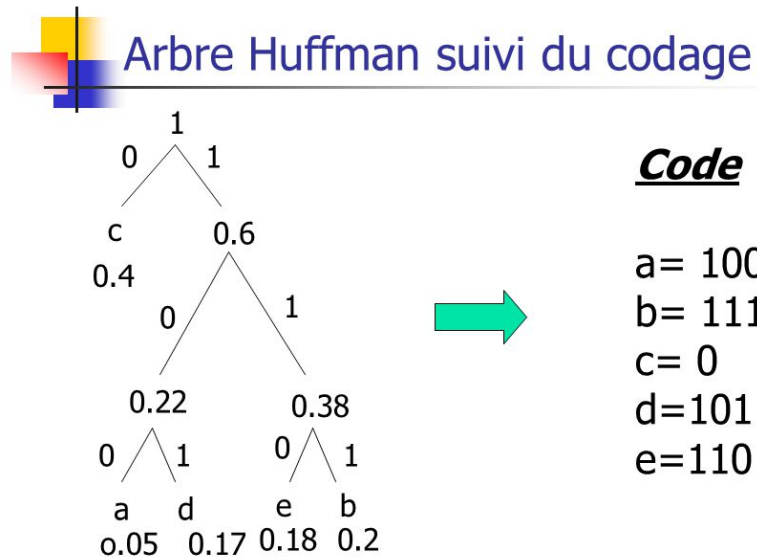
On a bien 2 groupe qui ont des somme a peu pres egale avec $a_1, a_2 > a_3, a_4, a_5, a_6$ ($0.54 > 0.46$), la somme des a vaux bien 1.

1.5.2 Code de Huffman

Déroulement de l'algorithme :

- 1-Trier les probabilités par ordre croissant
- 2-Créer un nœud parent à partir de 2 lettres sources avec les probabilités les plus faibles
- 3-Affecter au nœud parent la somme des 2 nœuds fils
- 4-Supprimer les nœuds enfants
- 5-Boucler de l'étape 2 à 5 jusqu'à ce que l'arbre soit rempli

Exemple :



10

Bonus : Code LZW (Lempel-Ziv-Welch) utilisé pour la compression des données.

1.5.3 Code Arithmétique

Chapitre 2 : Code Correcteur d'erreur / Code d'étalement

2.1 Introduction

Un code correcteur d'erreur peut être représenté sous forme matricielle. Lors de la transmission numérique d'un signal, il peut y avoir des causes d'erreur dues au bruit (thermique, impulsif, intermodulation, ...), de la distortion, de l'écho ou du canal hertzien etc... En général, on ne peut agir sur le canal de transmission ou préférer se préoccuper sur le signal numérique pour des contraintes technologiques et économiques.

On peut distinguer 2 types d'erreur :

- Les erreurs aléatoires dues aux bruits blancs.
- Les erreurs par paquets (impulsif, parasite).

Definition

bruit blanc : On appelle la lumière blanche la superposition des ondes visibles du spectre. Et bien lorsqu'on superpose les fréquences audibles, on obtient le bruit blanc. C'est un assemblage de plusieurs sons qui donnent un seul son uniforme.

2.2 Code Correcteur

Il existe 2 types de codes :

- Code en bloc
- Code convolutionnel

Un code est appelé $C(n, m)$, la redondance est définie par : $\frac{m}{n} = 1 - \frac{k}{n} < 1$

2.2.1 Code en Bloc

Le message est découpé en bloc de m bits (*élément binaire*) de longueur fixe (m constant). À chaque bloc de m bits, le codeur ajoute k bits de contrôle (appelé checksum dans le cas du réseau). On va écrire $n = m + k$, $n : m + k$ (n composé de $m + k$) \Rightarrow code séparable ou systématique.


2.2.2 Code Convolutionnel

Des éb (échantillon binaire) de contrôle sont introduits de manière continue dans le message utile. éb bloc : ajouter k éb de contrôle, dépend du bloc de

contrôle et antérieure \Rightarrow code récurrent.

2.3 Détection et Correction d'erreur

Cas d'un canal sans symbole d'effacement.




Code linéaire C de distance minimum dm permet de :

- Détecter au plus $dm - 1$ erreur
- Corriger au plus $t = \frac{dm-1}{2}$ erreur (entier)

On dit qu'un code est linéaire systématique. (linéaire : information envoyée et messages reçus, systématique : envoie bits de contrôle)

Cas d'un canal avec symbole d'effacement :



- Détecte au plus $\rho + 1 \leq dm$
- Corrige $2t + \rho + 1 \leq dm$

Code Parfait :

Une condition nécessaire est suffisante pour qu'un code linéaire C de distance minimum dm soit parfait :

$$\sum_{i=0}^t C_n^i (q-1)^i = q^k$$

La **matrice generatrice** est utiliser dans le cas des code lineaire ,exemple :
Avec $n=4$ et $m=2$ ou (n :nombre de mot , m :la longueur du mot)

On a $g^1 = \begin{pmatrix} 1 \\ 0 \\ 0 \\ 0 \end{pmatrix}$ et $g^2 = \begin{pmatrix} 0 \\ 1 \\ 0 \\ 0 \end{pmatrix}$

$$U = \begin{bmatrix} 1 & 0 \\ 0 & 1 \\ 0 & 0 \\ 0 & 0 \end{bmatrix} \times \begin{pmatrix} x \\ y \end{pmatrix}$$

On va ensuite prendre chaque mot et effectuer le produit matriciel par U :

$$\begin{bmatrix} 1 & 0 \\ 0 & 1 \\ 0 & 0 \\ 0 & 0 \end{bmatrix} \times \begin{bmatrix} 1 \\ 0 \end{bmatrix} = \begin{bmatrix} 1 \\ 0 \\ 0 \\ 0 \end{bmatrix}$$

On peut écrire le poids dm (nb de 1) de chaque mot coder : 0 , 1 , 1 , 2 ici $dm=1$ (poids le plus faible)

Et $\frac{dm-1}{2}$ Correction

c5 = m1+m2

$$G =$$

	$\text{Sm } \text{tm}$	
tm	0 1	10
Sm	1 0	01
-----	-----	-----
$\text{Sm} + \text{tm}$	1 1	11
tm	0 1	01
$\text{Sm} + \text{tm}$	1 1	11

Matrice de controle :

Elle se note : $H = \begin{bmatrix} -P^T \\ I \end{bmatrix} \Rightarrow H^T = \begin{bmatrix} P \\ I \end{bmatrix} = \begin{bmatrix} 1 & 1 & \| & 1 & 0 & 0 \\ 1 & 0 & \| & 0 & 1 & 0 \\ 1 & 1 & \| & 0 & 0 & 1 \end{bmatrix}$

$$G^T H = 0$$

Syndrome :

C est un mot codé , alors $H^T C = 0$

y est un mot reçu , syndrome de y : $s(y) = H^T y$

$y = C + e$ avec e : erreur [0010] (on met un 1 sur le bit erroné)

Donc $s(y) = s(C + e) = H^T C + H^T e = H^T e$

Procédure :

-Calculer $s(y) = H^T y$

-Si $s(y) = 0$ alors y est le mot code

-Sinon on cherche une séquence Z de longueur n telle que $H^T Z = s(y)$,

$C = y + Z$

2.5 Séquence d'hadamard

Elle se définit comme suit et est de taille minimal 8 : $\begin{bmatrix} H & H \\ H & -H \end{bmatrix}$

On commence à $H_0 = [1]$

$$H_1 = \begin{bmatrix} [1] & 1 \\ 1 & -1 \end{bmatrix}$$

$$H_2 = \begin{bmatrix} \begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix} & \begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix} \\ \begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix} & \begin{bmatrix} -1 & -1 \\ -1 & 1 \end{bmatrix} \end{bmatrix}$$

$$H_3 = \begin{bmatrix} \begin{bmatrix} 1 & 1 & 1 & 1 \\ 1 & -1 & 1 & -1 \\ 1 & 1 & -1 & -1 \\ 1 & -1 & -1 & 1 \end{bmatrix} & \begin{bmatrix} 1 & 1 & 1 & 1 \\ 1 & -1 & 1 & -1 \\ 1 & 1 & -1 & -1 \\ 1 & -1 & -1 & 1 \end{bmatrix} \\ \begin{bmatrix} 1 & 1 & 1 & 1 \\ 1 & -1 & 1 & -1 \\ 1 & 1 & -1 & -1 \\ 1 & -1 & -1 & 1 \end{bmatrix} & \begin{bmatrix} -1 & -1 & -1 & -1 \\ -1 & 1 & -1 & 1 \\ -1 & -1 & 1 & 1 \\ -1 & 1 & 1 & -1 \end{bmatrix} \end{bmatrix}$$

Chaque ligne de la matrice correspond à une séquence , il y en a donc 8 par défaut .

Si un utilisateur U_1 veut transmettre la séquence S_1 "101" en utilisant la séquence 2 (2ème ligne de la matrice) , on auras donc :

S_1 : "1" sera codé par la 2ème ligne donc "1 -1 1 -1 1 -1 1 -1" et "0" par son inverse "-1 1 -1 1 -1 1 -1 1"

$S_1 = "101" \Rightarrow "1 -1 1 -1 1 -1 1 -1" - "1 -1 1 -1 1 -1 1 -1" = "1 -1 1 -1 1 -1 1 -1"$

Si U_2 veut transmettre "011" on lui attribue la séquence 4 par exemple (4ième ligne de H), on aura donc :

$$S_2 = "011" \Rightarrow " - 111 - 1 - 111 - 1 " " 1 - 1 - 111 - 1 - 11 " " 1 - 1 - 111 - 1 - 11 "$$

Maintenant si U_1 et U_2 veulent mettre en même temps, il faudra faire une opération d'élément S :

$$S = S_1 + S_2$$

$$S = "002 - 2002 - 2 " " 00 - 2200 " " 2 - 2002 - 200 "$$

Chapitre 3 : Code Cyclique/ Pseudo-Aleatoire

3.1 Code Pseudo Aleatoire

Un nombre n'étant pas aléatoire, on va piocher une partie d'une très grande séquence binaire. Cette sous-séquence sera générée de telle sorte qu'il ne sera presque impossible de trouver la même sous-séquence.

La Séquence doit être :


- 1) Générer facilement (seq. binaire 0,1)
- 2) Suffisamment longue
- 3) Difficilement reconstituable par petit segment
- 4) Distribution des bits qui apparaît de façon aléatoire (évite les mêmes suites de 0 et 1 ex : 001 01 001 1 001 001)

Solution : utiliser code à longueur maximale (LM), code Gold ou JPL.

3.1.1 Code à Longueur Maximal LM

La fonction c , $\text{rand}()$ utilise un code LM.

Principe : Il s'agit de registre à décalage en réaction linéaire composé de n étages.




Le schéma peut représenter un polynôme de second degré, ce système permet d'avoir autant de 0 que de 1 (Distributivité), $L = (2^n - 1)$ bits (L : taille)

L'addition mod(2) d'une séquence LM avec une séquence décalée/repliée

sur elle meme donne \Rightarrow *unesequenceLMrepliqu*


3.1.2 Code Gold

Implemente le code LM mais permet de generer des sequence encore plus longue . Utilise dans le systeme CDMA (AMRC en anglais).



Inutile si on prend 2 fois le meme sequence car LM1 et LM2 sont demarrer et initialiser en meme temps .

Exemple : **Registre a decalage** de longueur 4



On preleve sur le 1er et 4ieme element [4,1].

-Initialisation : cela peut etre fait avec des valeurs quelconque de la sequence "0000" , en generale on initialise a "1111".

Principe :

- 1) Decalage de la sequence de 1 rang vers la droite
- 2) Xor [4,1] : On fait un ou-exclusif sur le 1er et le 4ieme element jusqu'a temps de retomber sur la sequence initial "1111"

Cn	1	1	1	1
$C(n+1)$	0	1	1	1
$C(n+2)$	1	0	1	1
$C(n+3)$	0	1	0	1
$C(n+4)$	1	0	1	0
$C(n+5)$	1	1	0	1

$C(n+6)$	0	1	1	0
$C(n+7)$	0	0	1	1
$C(n+8)$	1	0	0	1
$C(n+9)$	0	1	0	0
$C(n+10)$	0	0	1	0
$C(n+11)$	0	0	0	1
$C(n+12)$	1	0	0	0
$C(n+13)$	1	1	0	0
$C(n+14)$	1	1	1	0
$C(n+15)$	1	1	1	1

$L = 2^n - 1 = 15$ (on prend pas la 1er ligne d'initialisation)

La lecture des C_n se lis en colonne , C_n commenceras donc par la premier ligne et $C(n+6)$ respectivement a la 6ieme lignes d'ou l'espace de le systeme, ce qui donne :

$C(n)$: 1111 0101 100 1000
 $C(n+6)$: 0110 0100 011 1101
 $C(n) \text{ xor } C(n+6) = 1001 0001 111 0101$

Propriete : -Il n'y a aucune serie de "0" de longueur R

- Il y a qu'une serie de "1" de longueur R
- Il y a qu'une serie de "0" de longueur R-1
- Il n'y a aucune serie de "1" de longueur R-1
- Il y a 2^{R-P-2} serie de "0" de longueur P
- Il y a 2^{R-P-2} serie de "1" de longueur P

Si on prend :


- R=4 : On a 0 serie de "0000" et 1 serie de "1111" (rouge)
- R-1=3 : On a 1 serie de "000" et 0 serie de "111" (vert)
- P=2 : On a $2^{4-2-2} = 2^0 = 1$ donc 1 serie de "00" et 1 serie de "11" (orange)
- P=1 : On a $2^{4-1-2} = 2^1 = 2$ donc 2 serie de "0" et 2 serie de "1" (bleue)



Note : Pour avoir les meilleur resultat , des chercheurs ont trouve un polynome qui possede assez de combinaisons pour etre dit fiable , on parle du polynome 89 [89,6,5,3]

3.1.3 Code JPL

Implementation de plusieurs codes LM avec une taille différente (nmp) , ce système est utilisé en radio-localisation (GPS).



LM1, LM2 et LM3 doivent être premiers entre eux .

3.2 Code Cyclique

Code le plus utilisé dans de nombreux systèmes. Les codes cycliques sont détecteurs et correcteurs d'erreur. Les bits de contrôle sont le reste de la division polynomiale.

Exemple :

Déterminez si le code engendré par la matrice est cyclique ? Avec $G = \begin{bmatrix} 1 & 1 & 0 & 0 \\ 0 & 1 & 1 & 0 \\ 0 & 0 & 1 & 1 \end{bmatrix}$

$\begin{bmatrix} 0 & 1 & 1 & 0 \\ 0 & 0 & 1 & 1 \end{bmatrix}$

On va effectuer le produit matriciel avec une matrice M

M=

0	0	0
---	---	---

0	0	1
---	---	---

0	1	0
---	---	---

0	1	1
---	---	---

1	0	0
---	---	---

1	0	1
---	---	---

1	1	0
---	---	---

1	1	1
---	---	---

On a donc $M \times G = C$

C=

0	0	0	0
---	---	---	---

0	0	1	1
---	---	---	---

0	1	1	0
---	---	---	---

0	1	0	1
---	---	---	---

1	1	0	0
---	---	---	---

1	1	1	1
---	---	---	---

1	0	1	0
---	---	---	---

1	0	0	1
---	---	---	---

Si on decale une ligne sur la gauche on retombe sur une autre ligne de la matrice , C est cyclique si tout les lignes sont decalable

Chapitre 4 : Temps Reel